

Exemples de quatre fonctions élémentaires en R

► [Chargement du fichier compressé de codes et de données \[dossier: "ADT_R"\]](#)

Les codes de ces quatre fonctions et leurs contextes d'utilisation constituent des exemples pédagogiques du livre *Analyse des données Textuelles* (L. Lebart, B. Pincemin, C. Poudat), Presse de l'Université du Québec, 2019, sous presse.

Le logiciel R est à la fois un langage et une bibliothèque. Comme Python, il s'agit d'un logiciel gratuit et multiplateforme. C'est la composante non exclusive du langage de programmation S (Chambers, 1998), elle-même dérivée des travaux d'une équipe de Bell Laboratories datant de 1976 (équipe composée de Rick Becker, John Chambers, Doug Dunn, Paul Tukey et Graham Wilkinson).

Sommaire

1- Compression et reconstruction d'images (avec affichage graphique)

2- Analyse en composantes principales (avec affichage graphique)

3- Analyse des correspondances (avec affichage graphique)

4- Calcul et tracé (sur un plan principal) de l'arbre de longueur minimale



1- Compression et reconstruction d'images (avec graphiques)

Comme pour Python, il s'agit simplement de pénétrer, grâce à R, dans la boîte noire d'une fonctionnalité banale disponible dans la plupart des logiciels statistiques d'analyse d'images.

Evidemment, le code pourrait être beaucoup plus compact, mais peut-être moins lisible.

Commandes pour l'interface R

```
#-----
source("c:\\ADT_R\\svd_image_E.r") # code source
path= "c:\\ADT_R\\Cheetah.txt"    # données (niveaux de
gris)
X=read.table(path, header=FALSE, row.names=1, sep = "")
nd = 8      # nombre d'axes pour la reconstitution (par
exemple)
Y = recons(X, nd)
visu_image(Y)
#-----
```

Le petit fichier de test de données «Cheetah.txt» est fourni dans le dossier ADT_R. C'est un tableau numérique simple (200 x 320) [niveaux de gris pour chaque pixel]. Voir: Nelson M. (1993). *La compression des données. Text, images, sons*. Dunod, Paris.

Cas d'une image plus générale au format ".pgm" (Portable Grey Map)

Le fichier "Cheetah.txt" dans cet exemple est une matrice simple, plus rustique que les formats d'image les plus courants (bmp, jpg, png). Ces images doivent être converties au format pgm par un logiciel libre tel que GIMP ou IrfanView. La matrice X de lignes de commande est ensuite obtenue à l'aide des quatre lignes de commande suivantes:

```
#-----
# Quatre lignes de commandes à substituer à la ligne:
# "X = read.table ..." dans le cas d'une image en
format pgm
#-----
install.packages ( "pixmap"); # à n'utiliser que la
première fois ! ...
library (pixmap); # chargement du "pixmap package"
imag = read.pnm ("c:\\ADT_R\\Cheetah.pgm"); # pour une
image "pgm"
X = 255 * imag @ gray; # On peut maintenant appeler la
fonction: recons ()
#-----
```

L'image ci-dessous est fournie par la fonction: recon():




Image obtenue après avoir saisi les lignes de commandes R . Taux de compression $200/8 = 25$ (8 axes principaux).



2- Analyse en composantes principales (avec affichage graphique)

Il s'agit simplement d'obtenir, grâce à R, une fonctionnalité disponible dans la plupart des logiciels statistiques d'analyse exploratoire multivariée.

Encore une fois, le code pourrait être beaucoup plus compact, mais peut-être moins lisible.

Commandes pour l'interface R

#-----

```

# Commandes pour l'interface R
source("c:/ADT_R/ACPS_E.r")           # emplacement
du code source
path= "c:/ADT_R/Mini_Semio.txt"       # emplacement
des données
X=read.table(path, header=TRUE, row.names=1, sep = ",")
# X = tableau de données
Y =ACP(X)                             # fonction
principale
plot_ind (Y, X, hor=2, ver=3, font = 1) # graphe des
individus (lignes)

                                     # (plane (2,
3) )
plot_var (Y, X, hor=2, ver=3, font = 1) # graphe des
variables (colonnes)

                                     # (plan (2, 3)
)
#-----

```

Le petit fichier de test de données «Mini_semio.txt» est fourni dans le dossier ADT_R. Il s'agit d'un simple tableau numérique (12 x 7) donnant les scores attribués par 12 répondants à un ensemble de 7 mots. La *liste sémiométrique* réelle contient 210 mots et la taille des échantillons varie de 800 à plusieurs milliers. Voir : *The Semiometric Challenge: Words, Lifestyles and Values* (L. Lebart, J-F. Steiner, M. Piron, J. Wisdom), *L2C*, 2014.  [\(Télécharger le livre - pdf\)](#)  [\(Télécharger la couverture du livre - pdf\)](#) ... et (en Français) *La sémiométrie* (L. Lebart, M. Piron, J.-F. Steiner), *Dunod*, 2003.  [\(Télécharger le livre - pdf\)](#)

Petit tableau-test ("Mini-semio.txt")

	arbre,	cadeau,	danger,	morale,	orage,	politesse,	sensuel
R01,	7,	4,	2,	2,	3,	1,	6
R02,	6,	3,	1,	2,	4,	1,	7
R03,	4,	5,	3,	4,	3,	4,	3
R04,	5,	5,	1,	7,	2,	7,	1
R05,	4,	5,	2,	7,	1,	6,	2
R06,	5,	7,	1,	5,	2,	6,	5
R07,	4,	2,	1,	3,	5,	3,	6
R08,	4,	1,	5,	4,	5,	4,	7
R09,	6,	6,	2,	4,	7,	5,	5
R10,	6,	6,	3,	5,	3,	6,	6
R11,	7,	7,	6,	7,	7,	6,	7
R12,	2,	2,	1,	2,	1,	3,	2

L'image ci-dessous est l'image produite par les fonctions `ACP()` et `plot_ind()`:




Image obtenue après avoir saisi les cinq lignes de commande R
Représentation des 12 répondants dans le plan "semiometrique" (2, 3)



3- Analyse de correspondance (avec affichage graphique)

Il s'agit d'un code simple et autonome pour l'analyse des correspondances, comprenant une représentation simultanée de lignes et de colonnes.

Encore une fois, le code pourrait être beaucoup plus compact, mais peut-être moins lisible.

Commandes pour l'interface R

```
#-----  
# Commandes à saisir dans l'interface R.  
# -----  
-----  
# fonction Y = aforc (X): Analyse de correspondance de  
la matrice X  
# -----  
-----  
# Exemple pour une table de contingence "tab.csv" dans  
le dossier ADT_R  
# (le code source: - aforc_E.r - se trouve dans le même  
dossier)  
  source ("c: /ADT_R/aforc_E.r") # emplacement du code  
source  
  path = "c: /ADT_R/tab.csv" # emplacement des données  
# chemin mène à un fichier Excel (c) [format csv]  
  X = read.csv (path, row.names = 1, sep = ";") # X =  
table de données  
  Y = aforc (X)  
  plot_simult (Y) # tracé simultané de lignes et de  
colonnes de la table de données  
#-----  
-----
```

Le petit fichier de test de données «tab.csv» est fourni dans le dossier ADT_R. C'est un tableau lexical simple (12 x 6) donnant les fréquences de 12 mots (lignes) dans les réponses de six catégories de répondants. à la question suivante dans une enquête par sondage:

«Personne ne peut expliquer pourquoi, peut-être à cause de ce qu'ils évoquent, nous trouvons certains mots agréables, d'autres désagréables.

- 1. En ce qui vous concerne personnellement, quels sont les mots que vous trouvez les plus agréables? (Citez autant de mots que possible).*
- 2. Quels sont les mots que vous trouvez les plus désagréables? (Citez autant de mots que possible). "*

C'est un cas de "sémiométrie ouverte" (sans liste de mots imposée), cf. Chapitre 4 du livre déjà cité: *The Semimetric Challenge: Words, Lifestyles and Values* (L. Lebart, J-F. Steiner, M. Piron, J. Wisdom), *L2C*, 2014.  [\(Téléchargez le livre - pdf\)](#)  [\(Téléchargez la couverture du livre - pdf\)](#) ... et (en Français) *La sémiométrie* (L. Lebart, M. Piron, J.-F. Steiner), *Dunod*, 2003.  [\(Téléchargez le livre - pdf\)](#)

Petit tableau de données - test ("tab.csv")

Ident	;	Hm30	Hm55	Hp55	Fm30	Fm55	Fp55
argent	;	11	15	6	14	9	3
courage	;	2	3	11	1	3	4
dormir	;	8	3	1	6	2	0
livre	;	2	7	1	9	11	11
maman	;	0	3	0	12	11	3
manger	;	9	5	1	10	3	1
pardon	;	1	2	6	0	5	5
peinture	;	0	0	1	2	7	3
plaisir	;	10	6	2	11	2	1
politesse	;	0	1	5	0	4	8
repas	;	3	5	4	0	3	1
soleil	;	26	32	23	54	56	42

Identifiants des colonnes (catégories de répondants):

Hm30 = Homme, moins de 30 ans;

Hm55 = Homme, entre 30 et 55 ans;

Hp55 = Homme, plus de 55 ans.

Fm30 = Femme, moins de 30 ans;

Fm55 = Femme, entre 30 et 55 ans;

Fp55 = Femme, plus de 55 ans.

L'image ci-dessous est produite par les fonctions `afcor()` et `plot_simult()`:




Image obtenue après avoir saisi les cinq lignes de commandes R



4- Calcul et tracé (sur un plan principal) de l'arbre de longueur minimale (ALM))

Le langage de base R est à nouveau utilisé volontairement sans aucune bibliothèque spécialisée. Un choix devait être fait entre les nombreuses méthodes de clustering. Nous avons choisi d'implémenter ici l'arbre de longueur minimale (fonction `armin()`) en utilisant l'algorithme de Prim. Les fonctions `print_armin` et `plot_armin` donnent respectivement la liste des arêtes de l'arbre et une représentation de celle-ci dans un plan principal. L'arbre est calculé ici à partir des coordonnées principales résultant d'une analyse de correspondance (fonction `afcor` dans la section 3 ci-dessus). Avec ces coordonnées, la distance euclidienne habituelle correspond à la distance Chi-2 calculée sur les données initiales..

Enfin, une petite fonction `afcor_armin_plot` (voir la fin du listing) fournit la séquence souhaitée. Elle est incluse dans le fichier `armin.r`, lui-même inclus dans le dossier intitulé `ADT_R`. Pour obtenir les résultats souhaités, écrivez simplement les lignes suivantes:

Commandes pour l'interface R

```
# -----
# Commandes à saisir dans l'interface R.
# -----
-----
# fonction composite Y = afcor_armin_plot (X) [dans le
dossier téléchargé ADT_R]
# -----
-----
# Exemple pour une table de contingence "tab.csv" dans
le dossier ADT_R
# (les codes sources: afcor_E.r et armin_R.r se
trouvant dans le même dossier ADT_R)
  source("c:/ADT_R/afcor_E.r")      # emplacement du code
source 1
  source("c:/ADT_R/armin_E.r"))    # emplacement du code
source 2
  path = "c:/ADT_R/tab.csv"        # emplacement des
données
# mêmes données que dans la section A3
  afcor_armin_plot(path)
#-----
-----
```

Le tableau ci-dessous est produit par la fonction `afcor_armin_plot()`:

Tableau des arêtes de l'ALM obtenues après la saisie des quatre lignes de commande R ci-dessus.

	NumDeb	arête	NumFin	NomDeb	arête	NomFin
[1,]	1	-----	9	argent	-----	plaisir
[2,]	9	-----	6	plaisir	-----	manger
[3,]	6	-----	3	manger	-----	dormir
[4,]	1	-----	12	argent	-----	soleil
[5,]	12	-----	4	soleil	-----	livre
[6,]	4	-----	5	livre	-----	maman
[7,]	1	-----	11	argent	-----	repas
[8,]	4	-----	8	livre	-----	peinture
[9,]	12	-----	7	soleil	-----	pardon
[10,]	7	-----	10	pardon	-----	politesse

NumDeb = *numéro d'origine*; NumFin = *num. extrémité*
 NomDeb = *Identificateur de l'origine*; NomFin = *Ident. extrémité*

L'image ci-dessous est l'image produite par la fonction **afcor_armin_plot()**:




Image obtenue après la saisie des quatre lignes de commande R ci-dessus.

[Accueil](#)